



CETI VIRTUAL

INGENIERÍA EN TECNOLOGÍA DE SOFTWARE

NOMBRE DE LA ASIGNATURA:

COMPUTACIÓN PARALELA

NOMBRE DEL PROFESOR:

HEBERT SERGEI PEREZ SANTANA

NOMBRE DE LA ACTIVIDAD:

Examen Extraordinario

NOMBRE DEL ALUMNO:

LUQUIN CASTRO JESUS EDUARDO

REGISTRO:

20310467

FECHA DE ELABORACION: 01/06/2024

Objetivo del Ejercicio:

El objetivo de este ejercicio es realizar un análisis exhaustivo de las relaciones entre entidades utilizando técnicas avanzadas de computación paralela en Python. Se busca calcular estadísticas detalladas sobre las relaciones más frecuentes y la distribución de tipos de relaciones dentro del grafo de conocimiento de YAGO. Además, se pretende implementar consultas paralelizadas para optimizar el procesamiento de grandes volúmenes de datos semánticos, explorando así la eficiencia y escalabilidad de las técnicas de paralelización en el análisis de datos complejos y estructurados como los proporcionados por YAGO.

Descripción del Proyecto:

Elegí la problemática de y la computación paralela nos ayuda a resolver el problema en un tiempo razonable.

Configuración del Entorno:

Hardware Recomendado:

- CPU: Procesador multicore Intel Core i7 o superior) para ejecución en paralelo utilizando Multiprocessing, Threading u otras técnicas.
- GPU (opcional): Tarjeta gráfica compatible con CUDA u openCL

Sistema Operativo

- Windows 10

Gestión de Entorno:

- Python: Versión 3.6 o superior.



Bibliotecas y Frameworks:

plaintext

requirements.txt

Bibliotecas básicas

numpy

scipy

pandas

matplotlib

multiprocessing

Computación paralela y procesamiento distribuido

dask[complete]

joblib

tensorflow (si se va a utilizar con GPU, instalar tensorflow-gpu)

pytorch (si se va a utilizar)

Web scraping (ejemplo adicional)

beautifulsoup4

requests



Explicación de las Bibliotecas y Frameworks

CETI VIRTUAL

numpy: Para operaciones numéricas eficientes y manejo de arrays.

INGENIERÍA EN TECNOLOGÍA DE SOFTWARE

- scipy: Para herramientas y algoritmos científicos.
- pandas: Para manipulación y análisis de datos.
- matplotlib: Para visualización de datos.
- dask: Para computación paralela y procesamiento distribuido.
- joblib: Para ejecución paralela de tareas.
- tensorflow o pytorch: Frameworks de aprendizaje profundo (deep learning) con soporte para ejecución en GPU si se instala la versión tensorflow-gpu.
- BeautifulSoup4 y requests: Para web scraping y manipulación de datos desde la web, como un ejemplo adicional de uso.

Instalación de Dependencias

Para instalar las dependencias desde el archivo requirements.txt, puedes ejecutar el siguiente comando en tu entorno virtual de Python:

```
bash
```

```
pip install -r requirements.txt
```

Consideraciones Adicionales

- Entorno Virtual: (venv o virtualenv) para aislar las dependencias del proyecto.

Implementación de tareas paralelas:

- **Multiprocesamiento:**

A diferencia del multiprocesamiento, los hilos comparten el mismo espacio de memoria, lo que puede ser beneficioso para tareas que requieren acceso a datos compartidos, aunque es necesario manejar adecuadamente la sincronización para evitar condiciones de carrera.

- **Multihilo:**

Primero, definimos las funciones para cada nivel del grafo que realizarán diferentes análisis sobre las ciudades. Aquí mostramos un ejemplo simplificado para dos niveles: demografía y economía.

- **GPU Computing:**

GPU Computing

Para implementar el proyecto utilizando una GPU, utilizaremos bibliotecas como TensorFlow con soporte para GPU. Aquí se mostrará cómo se puede lograr una aceleración significativa en comparación con una implementación basada solo en CPU.

- **Sincronización y Control de Concurrencia:**

Para implementar mecanismos de sincronización, podemos utilizar semáforos y bloqueos (locks) en Python para asegurarnos de que nuestra solución esté libre de condiciones de carrera (race conditions) y otros problemas de concurrencia.

- **Benchmarking y Análisis de Rendimiento:**

En este ejemplo, se utilizan locks para proteger el incremento de un contador global y semaphores para limitar el número de hilos que pueden acceder simultáneamente a un recurso. Esto ayuda a evitar condiciones de carrera y a asegurar la correcta sincronización entre los hilos.

- **Documentación:**

Documentación

Código Documentado

python

import time

import threading

import multiprocessing

Función para calcular la demografía de una ciudad

```
def calculate_demographics(city):
```

```
    time.sleep(1)
```

```
    return f"Demografía de {city}"
```

Función para analizar la economía de una ciudad

```
def analyze_economics(city):
```

```
    time.sleep(2)
```

```
    return f"Análisis económico de {city}"
```

Ejecución secuencial

```
def sequential_execution(cities):
```

```
    results_demographics = [calculate_demographics(city) for city in cities]
```

```
    results_economics = [analyze_economics(city) for city in cities]
```

```
    return results_demographics, results_economics
```

Ejecución paralela con hilos

```
def parallel_execution_threads(cities):
```

```
    results_demographics = [None] * len(cities)
```

```
    results_economics = [None] * len(cities)
```



```
threads_demographics = []
for i, city in enumerate(cities):
    thread = threading.Thread(target=calculate_demographics, args=(city,
results_demographics, i))

    threads_demographics.append(thread)

    thread.start()
```

```
threads_economics = []

for i, city in enumerate(cities):

    thread = threading.Thread(target=analyze_economics, args=(city,
results_economics, i))

    threads_economics.append(thread)

    thread.start()
```

```
for thread in threads_demographics:
```

```
    thread.join()
```

```
for thread in threads_economics:
```

```
    thread.join()
```

```
return results_demographics, results_economics
```

```
# Ejecución paralela con multiprocessing
```

```
def parallel_execution_multiprocessing(cities):
```




with multiprocessing.Pool() as pool:

```
results_demographics = pool.map(calculate_demographics, cities)
```

```
results_economics = pool.map(analyze_economics, cities)
```

```
return results_demographics, results_economics
```

CETI VIRTUAL

INGENIERÍA EN TECNOLOGÍA DE SOFTWARE

Medir tiempo de ejecución

```
def measure_execution_time(func, *args):
```

```
    start_time = time.time()
```

```
    results = func(*args)
```

```
    end_time = time.time()
```

```
    execution_time = end_time - start_time
```

```
    return execution_time, results
```

Benchmark de tiempo de ejecución

```
def benchmark():
```

```
    cities = ['Guadalajara', 'Ciudad de México', 'Monterrey', 'Cancún', 'Mérida']
```

```
    seq_time, seq_results = measure_execution_time(sequential_execution, cities)
```

```
    print(f"Tiempo de ejecución secuencial: {seq_time} segundos")
```

```
    thr_time, thr_results = measure_execution_time(parallel_execution_threads, cities)
```

```
    print(f"Tiempo de ejecución con hilos: {thr_time} segundos")
```



```
mp_time, mp_results = measure_execution_time(parallel_execution_multiprocessing,
```

CETI VIRTUAL

INGENIERÍA EN TECNOLOGÍA DE SOFTWARE

```
print(f"Tiempo de ejecución con multiprocesamiento: {mp_time} segundos")
```

```
# Medir uso de recursos
```

```
def measure_resource_usage(func, *args):
```

```
    process = psutil.Process()
```

```
    start_time = time.time()
```

```
    results = func(*args)
```

```
    end_time = time.time()
```

```
    execution_time = end_time - start_time
```

```
    cpu_usage = process.cpu_percent(interval=1)
```

```
    memory_usage = process.memory_info().rss / (1024 * 1024) # Convertir a MB
```

```
    return execution_time, cpu_usage, memory_usage, results
```

```
# Benchmark de uso de recursos
```

```
def benchmark_resources():
```

```
    cities = ['Guadalajara', 'Ciudad de México', 'Monterrey', 'Cancún', 'Mérida']
```

```
    print("Benchmark de Recursos para Ejecución Secuencial:")
```

```
    seq_time, seq_cpu, seq_memory, seq_results =
```

```
    measure_resource_usage(sequential_execution, cities)
```

```
    print(f"Tiempo de ejecución: {seq_time} segundos")
```



```
print(f"Uso de CPU: {seq_cpu}%")
```

```
print(f"Uso de Memoria: {seq_memory} MB\n")
```

CETI VIRTUAL

INGENIERÍA EN TECNOLOGÍA DE SOFTWARE

```
print("Benchmark de Recursos para Ejecución con Hilos:")
```

```
thr_time, thr_cpu, thr_memory, thr_results =
```

```
measure_resource_usage(parallel_execution_threads, cities)
```

```
print(f"Tiempo de ejecución: {thr_time} segundos")
```

```
print(f"Uso de CPU: {thr_cpu}%")
```

```
print(f"Uso de Memoria: {thr_memory} MB\n")
```

```
print("Benchmark de Recursos para Ejecución con Multiprocesamiento:")
```

```
mp_time, mp_cpu, mp_memory, mp_results =
```

```
measure_resource_usage(parallel_execution_multiprocessing, cities)
```

```
print(f"Tiempo de ejecución: {mp_time} segundos")
```

```
print(f"Uso de CPU: {mp_cpu}%")
```

```
print(f"Uso de Memoria: {mp_memory} MB\n")
```

```
if __name__ == "__main__":
```

```
    benchmark()
```

```
    benchmark_resources()
```

Archivo README.md

markdown

Análisis Paralelo del Grafo de Ciudades Mexicanas



Este proyecto implementa y compara soluciones secuenciales y paralelas (usando hilos y multiprocessing) para analizar un grafo de 5 ciudades mexicanas en 7 niveles.

- Bibliotecas: numpy, scipy, pandas, matplotlib, dask[complete], joblib, tensorflow (tensorflow-gpu opcional), pytorch, beautifulsoup4, requests, psutil

Instala las dependencias con:

```
```bash
```

```
pip install -r requirements.txt
```

Ejecución

Para ejecutar el benchmark de tiempo de ejecución:

```
bash
```

```
python benchmark.py
```

Para ejecutar el benchmark de uso de recursos:

```
bash
```

```
python benchmark_resources.py
```



## Estructura del Proyecto

benchmark.py: Contiene la implementación del benchmark de tiempo de ejecución.

benchmark\_resources.py: Contiene la implementación del benchmark de uso de recursos.

requirements.txt: Lista de bibliotecas necesarias para el proyecto.

## Resultados

Los resultados del análisis incluyen el tiempo de ejecución y el uso de recursos (CPU y memoria) para cada enfoque (secuencial, hilos y multiprocesamiento).